Задачи по байесовскому подходу к классификации

Денисов Д.М.

Исходные данные:

$$p(x|y = -1) = \frac{1}{\pi(1+x^2)} \sim Cauchy(0,1),$$

$$p(x|y = +1) = \frac{1}{3}I_{[a,b]} \sim U(0,3),$$

$$\lambda_{-} = 2, \ \lambda_{+} = 1,$$

$$p(y = -1) = 0.4, \ p(y = +1) = 0.6.$$

1 Оптимальный байесовский классификатор

Имеем:

$$\begin{split} a^*(x) &= \underset{y}{\operatorname{argmax}} \ \lambda_y P(y) p(x|y) \\ &= \underset{y}{\operatorname{argmax}} \ \left\{ \lambda_- P(y=-1) p(x|y=-1), \lambda_+ P(y=+1) p(x|y=+1) \right\} \\ &= \underset{y}{\operatorname{argmax}} \ \left\{ \frac{0.8}{\pi(1+x^2)}, 0.2 I_{[a,b]} \right\} \\ &= \underset{y}{\operatorname{argmax}} \ \left\{ f(x), g(x) \right\}. \end{split}$$

Графики распределений f(x) и g(x) представлены на рис. 1. Из рис. 1 видно, что

$$g(x) \ge f(x) \iff x \in [x_0, 3].$$

Таким образом, оптимальный классификатор будет иметь вид

$$a^*(x) = \begin{cases} -1, & x \in (-\infty, x_0) \cup (3, +\infty) \\ +1, & x \in [x_0, 3] \end{cases}.$$

Координату x_0 найдём следующим образом:

$$f(x_0) = g(x_0) = 0.2 \implies \frac{0.8}{\pi(1 + x_0^2)} = 0.2 \implies$$

 $\implies \pi(1 + x_0^2) = 4 \implies x_0 = \sqrt{\frac{4}{\pi} - 1}.$

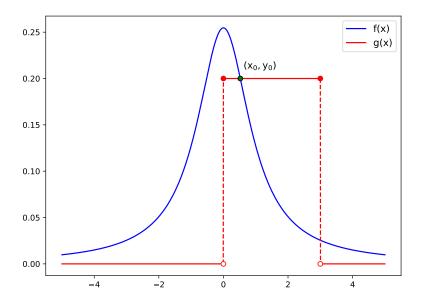


Рис. 1: Графики распределений

2 Оптимальный средний риск

Имеем:

$$\begin{split} R^* &= \int\!\!\!\int L(a^*(x),y) p(x,y) \, dx \, dy \\ &= \int\!\!\!\int \lambda_y [a^*(x) \neq y] p(x|y) P(y) \, dx \, dy \\ &= \int\!\!\!\int \lambda_y (1 - [a^*(x) = y]) p(x|y) P(y) \, dx \, dy \\ &= \int \min_y \, \lambda_y p(x|y) P(y) \, dx \, dy \\ &= \int \min_y \, \left\{ \lambda_- p(x|y = -1) P(y = -1), \lambda_+ p(x|y = +1) P(y = +1) \right\} dx \, dy \\ &= \int \min_y \, \left\{ f(x), g(x) \right\} dx \, dy. \end{split}$$

Аналогично пункту 1, получаем:

$$R^* = \int_{-\infty}^{x_0} g(x) dx + \int_{x_0}^{3} f(x) dx + \int_{3}^{+\infty} g(x) dx$$
$$= \int_{0}^{x_0} 0.2 dx + \int_{x_0}^{3} \frac{0.8}{\pi (1 + x^2)} dx$$
$$= 0.2x_0 + \frac{0.8}{\pi} (\arctan 3 - \arctan x_0) \approx 0.299958 \approx 0.3.$$

3 Наивный байесовский классификатор

Имеем:

$$p(x_1, x_2|y) = p(x_1|y)p(x_2|y).$$

Предположим, что исходные данные соответствуют нормальному распределению, то есть

$$p(x_1|y=-1) \sim N(\mu_{11}, \sigma_{11}^2), \ p(x_2|y=-1) \sim N(\mu_{21}, \sigma_{21}^2),$$

 $p(x_1|y=+1) \sim N(\mu_{12}, \sigma_{12}^2), \ p(x_2|y=+1) \sim N(\mu_{22}, \sigma_{22}^2).$

Определим параметры распределений: